

Šepetanje modelom za neračunalničarje

Ana Halužan Vasle

Verzija 1.2

Študijsko leto 2025/2026

Zahvala

Zahvaljujem se nosilcu predmeta Osnove programiranja, prof. dr. Mihi Moškonu, za prepoznavo pomembnosti obravnavane teme, pregled skripte in možnosti predstavitve v okviru predmeta.

Kazalo

	4
1 Veliki jezikovni modeli	8
2 Šepetanje modelom s pozivi	10
2.1 Vzorec obrnjene interakcije (angl. <i>flipped interaction pattern</i>)	12
2.2 Vzorec osebnosti in vzorec osebnosti občinstva (angl. <i>persona pattern</i> in <i>audience persona pattern</i>)	13
2.3 Vzorec izboljšanja vprašanja (angl. <i>question refinement pattern</i>)	15
2.4 Vzorec alternativnih pristopov (angl. <i>alternative approaches pattern</i>)	16
2.5 Kognitivni preverjalnik (angl. <i>cognitive verifier</i>)	17
2.6 Vzorec verige razmišljanja (angl. <i>chain of thought</i>)	18
2.7 Vzorec predloge (angl. <i>template pattern</i>)	19
2.8 Vzorec refleksije (angl. <i>reflection pattern</i>)	21
3 Izboljševanje pozivov (angl. <i>prompt-tuning</i>)	22
4 Razmišljujoči modeli (angl. <i>reasoning models</i>)	23
5 Zaključek	24

Predgovor

V zadnjih letih so veliki jezikovni modeli (angl. *large language models*, LLM) postali pomemben del znanstvenega dela, vsakdanje komunikacije in celo ustvarjalnih procesov. Njihovo hitro širjenje je prineslo paradoks: čeprav jih uporablja veliko znanstvenikov in študentov, le redki znajo z njimi res učinkovito komunicirati. Cilj pričujoče skripte je ponuditi strukturiran uvod v učinkovito interakcijo z orodji LLM, ki omogoča čim boljše izkoriščanje njihovega potenciala ter premišljeno, kritično in produktivno uporabo pri vašem delu.

Osnovo skripte predstavlja članek [3], ki sem ga razširila z dodatnimi viri, izvirnimi primeri pozivov (angl. *prompts*) in lastnimi izkušnjami pri delu z LLM. Poudarek je na praktični uporabi: kako pripraviti boljše pozive, izboljšati kakovost odgovorov ter vključiti modele kot aktivne sodelavce in ne zgolj pasivna orodja.

Ker je večina besedilnih korpusov za treniranje LLM v angleščini, so tudi primeri v tej skripti zapisani v angleščini. Uporaba tega jezika namreč največkrat zagotavlja najbolj celovite in zanesljive rezultate. Ob tem velja poudariti, da raziskovalci na Fakulteti za računalništvo in informatiko (FRI) pripravljajo tudi slovenski LLM, poimenovan GaMS¹, kar bo pomemben korak k večji jezikovni raznolikosti in dostopnosti umetne inteligence.

Na tem mestu bi se dotaknila še terminologije: marsikateri tehnični izraz v angleščini še nima ustaljenega slovenskega prevoda. V skripti sem se potrudila zagotoviti čim bolj ustrezne slovenske ustreznice. Razvoj strokovnih izrazov je namreč del širšega procesa umeščanja umetne inteligence v slovensko govoreče okolje.

Upam, da vam bo skripta v pomoč pri uporabi LLM-jev. Z razumevanjem učinkovitih načinov komuniciranja z njimi boste lahko obogatili ne le svoje raziskovalno delo, temveč tudi prispevali k oblikovanju kulture premišljene in odgovorne rabe ene najbolj preoblikujočih tehnologij našega časa.

¹<https://povejmo.si/klepet/>

1 Veliki jezikovni modeli

Veliki jezikovni modeli (LLM, angl. *large language models*) so sistemi umetne inteligence, naučeni na ogromnih količinah besedil. Vhodna besedila pomagajo pri učenju vzorcev, pomenov in kontekstov jezika, kar nato omogoča generiranje besedil, podobnih naravnemu jeziku.

V ozadju LLM so napovedni modeli, ki vzamejo zaporedje besed in poskušajo napovedati najbolj verjetno zaporedje, ki bo sledilo danemu zaporedju. To storijo tako, da na podlagi analize besedil, na katerih so bili naučeni, določijo verjetnost pojavljanja naslednjih besed in na podlagi predhodnih nastavitev ter izračunanih verjetnosti izberejo naslednjo besedo [14]. Katera beseda bo izbrana, je odvisno od nastavitev, kot sta temperatura (angl. *temperature*, **temperature**) in vzorčenje jedra (angl. *nucleus sampling*, **top-p**).

Nastavitev **temperature** kontrolira stopnjo naključnosti pri izbiri posameznih besed v odgovoru. Zavzame lahko vrednost med 0 in 1. Bolj kot je vrednost blizu 0, bolj model izbira najbolj verjetne besede in/ali fraze. Vrednosti bližje 1 pa omogočajo modelu, da izbira tudi manj verjetne izraze in s tem doda izvirnost. Nižje vrednosti tega parametra so tako primerne za naloge, kjer sta natančnost in doslednost ključna, medtem ko višje temperature spodbujajo ustvarjalnost, na primer pri pisanju zgodb ali generiranju idej [12, 14].

Vzorčenje jedra, **top-p**, določa, med kako širokim naborom najbolj verjetnih besed model izbira naslednjo besedo. Vrednost **top-p** 0,5 torej pomeni, da bo model izbral samo med tistimi besedami, katerih skupna verjetnost dosega 50 %, s čimer izpušča manj verjetne možnosti. Ko dvignemo **top-p** na 0,9, povečamo nabor možnih besed, s čimer model dobi več možnosti in se odziva bolj raznoliko in kreativno. Kakor pri temperaturi, je tudi optimalna izbira te vrednosti povezana z naravo naloge in ciljem interakcije [12].

Za lažjo predstavo, kaj pomenita **temperature** in **top-p** v praksi, obravnavajmo seznam 10 besed, ki jih bi LLM lahko uporabil v nadaljevanju stavka, ki mu je bil podan: [posledično, ker, kot, torej, signifikantno, precej, skladno, pričakovano, upošteva, sorazmerno]. Predpostavimo, da so urejene po padajoči verjetnosti. Če nastavimo temperaturo na 0.8, bo model z večjo verjetnostjo izbral besede, ki so bolj verjetne - npr. prve štiri se bodo pojavile večkrat kot ostale. S **top-p** pa lahko zamejimo ta nabor in omejimo le na prve štiri besede, kar pomeni, da se bosta pri temperaturi 0.8 večkrat pojavili npr. prvi dve ter nobena od četrte dalje.

Veliki jezikovni modeli so omejeni s količino enot besedila, t.i. žetoni (angl. *tokens*), ki jih model lahko procesira v enem poizvedbi ali odgovoru. Token obsega približno štiri angleške črke, zato se pogosto ne ujema popolnoma z besedami. Model GPT-4 lahko obdeluje do 32768 žetonov hkrati, kar omogoča delo s precej dolgimi besedilnimi vhodi in odgovori. Modelu lahko nastavimo tudi največje število žetonov, tj. **max_token**. Če je ta parameter nastavljen na 4096 žetonov in vhodna poizvedba porabi 1000 žetonov, bo model lahko ustvaril odgovor do največ 3096 žetonov. Parameter **max_token** vključuje tudi zgodovino pogovora, če se ta ohranja, kar omogoča kontinuiteto in boljše razumevanje konteksta odgovora [14].

Med vidnejšimi modeli LLM so ChatGPT (OpenAI), Claude/Opus/Sonnet (Anthropic), Gemini (Google), LLaMA (Meta), Perplexity (Perplexity AI), DeepSeek (DeepSeek AI) in Grok (xAI)[6, 8, 9].

ChatGPT (OpenAI) je eden najbolj vsestranskih in priljubljenih modelov LLM, ki se odlično znajde pri razumevanju naravnega jezika, ustvarjanju vsebin (tudi slik), programiranju, prevajanju in nalogah, ki zahtevajo kompleksno razmišljanje. Integriran je v številne aplikacije, a lahko včasih generira splošne ali manj točne odgovore, še posebej, kadar nima dostopa do aktualnih podatkov (plačljiva verzija omogoča dostop do spleta).

Claude (Anthropic) odlikuje močna etika in skladnost z varnostno uporabo ter varovanjem zasebnosti. Čeprav je manj vsestranski kot ChatGPT, je odličen za delo z velikimi dokumenti ter pri reševanju zahtevnih nalog, hkrati pa je manj dovzeten za halucinacije.

Gemini (Google) je eden prvih modelov, ki uspešno parira ChatGPT v reasoning in razumevanju konteksta, še posebej v znanstvenih domenah. Ima ogromno količino žetonov, kar omogoča obdelavo dolgih besedil in dokumentov. Zelo močan je na področju matematike, logike in znanosti. Integriran je v Googlov ekosistem Google Workspace, zunaj katerega pa je redko uporabljen.

LLaMA (Meta) je odprtokoden model z močno akademsko podporo, namenjen predvsem raziskovalcem in razvojne ekipe. Odprtokodnost omogoča prilagodljivost in nadzor nad modelom. Ker ga je mogoče samostojno gostovati in prilagajati, je dobra izbira za organizacije, ki potrebujejo zasebnost ali specializirane funkcionalnosti, vendar zahteva tehnično znanje za zagon in vzdrževanje. Super je za večjezične modele.

Perplexity (Perplexity AI) v glavnem poganjata ChatGPT in Claude, pridruženih pa je sicer več različnih LLM. Ker ima dostop do spleta in se osredotoča na generacijo odgovorov, podprtih z viri, je zelo priljubljen za raziskovanje. Vendar pa njegova ustvarjalnost in zmožnost dolgoročnega razumevanja konteksta ne dosežeta ravni ChatGPT.

DeepSeek (DeepSeek AI) je specializiran za analitične naloge, predvsem je odličen v delu s problemi STEM na področju matematike, programiranja, tehničnih raziskav. Manj učinkovit je v vsakdanjem pogovoru in ustvarjalnih nalogah.

Grok (xAI) je združuje močno razumevanje naravnega jezika z optimizacijo za interaktivna pogovorna okolja, kot je platforma X. Je hiter in daje jedrnate odgovore. V primerjavi s ChatGPT ima bolj omejen nabor funkcionalnosti in je slabše učinkovit pri obdelavi dolgih dokumentov.

Univerzalnega modela, ki bi bil najboljši za vsako nalogo, ni – izbira najustrežnejšega LLM je vedno odvisna od konteksta problema in zelenih ciljev. Prav zato je poznavanje razlik med posameznimi modeli ključno, saj nam omogoča izbiro tistega LLM ali več njih, ki najbolj ustrezajo specifični nalogi, ter s tem učinkoviteje izkoristimo njihov potencial.

2 Šepetanje modelom s pozivi

Kmalu po prihodu ChatGPT so uporabniki opazili, da je zmogljivost LLM močno odvisna od načina podajanja navodil tem modelom [1]. Kakor pri učenju jezikov tudi pri šepetanju modelov velja, da zgolj poznavanje jezika še ne zagotavlja dobrih komunikacijskih veščin - kot tudi dobre komunikacijske veščine še ne zagotavljajo učinkovite komunikacije [5].

Cilj šepetanja modelom je upravljanje in izpopolnjevanje komunikacije med uporabnikom in LLM namenom usmerjanja zmogljivosti LLM za specifično nalogo. Šepetanje modelom (angl. *prompt engineering*) nam omogoča usmerjanje zmogljivosti LLM v specifične naloge. Gre za način programiranja z jezikovnimi navodili, imenovanimi pozivi (angl. *prompts*, s katerimi modelu podamo usmeritve, navodila in/ali kontekst za pridobitev želenih odgovorov. Cilj šepetanja modelom je doseči čim bolj natančno, uporabno in relevantno interakcijo, saj kakovost in jasnost prompta neposredno vplivata na kakovost izhoda modela [4, 5, 7].

Pozivi načeloma vsebujejo štiri elemente: navodila, kontekst, vhodne podatke in indikator izhoda.

Navodila podajo specifično nalogo, ki usmeri obnašanje modela - npr. "Proofread the attached text."

Dodatno znanje in zunanje informacije modelu podamo s **kontekstom**, ki modelu pomaga pri generiranju relevantnih odgovorov - npr. "This is an email that needs to follow official corporate style."

Jedro poziva, ki vodi LLM razumevanje naloge so **vhodni podatki**. Ti so predstavljeni v obliki vnosa ali vprašanja, za katerega želimo, da ga model sprocesa in spiše odgovor.

Indikator izhoda določa tip ali obliko želenega izhoda (npr. kratek odgovor, odstavek, itd.). [2]

Poziv ni le zadnje navodilo, ki smo ga vpisali v okence za vnos, temveč celoten pogovor med nami in modelom. Po vnosu vsakega novega poziva se celotna vsebina pogovora pošlje nazaj v LLM, ki nato na osnovi vsega generira nov odgovor [4].

Pozivi so zelo pomemben del učinkovite uporabe LLM. Slabo definirani pozivi lahko vodijo v dvoumne odgovore, pri zelo specifičnih temah pa modeli pogosto ne vračajo zanesljivih informacij. Za učinkovito delovanje potrebujejo jasen in zadosten kontekst – premalo podatkov omejuje razumevanje, preveč pa lahko pozornost modela usmeri na nepomembne vidike. Ker LLM sami po sebi nimajo vrednot ali etičnega sistema, je etičnost njihove uporabe in ponujenih odgovorov odgovornost uporabnika [2].

V nadaljevanju se bomo osredotočili na nekatere pogosto uporabljane vzorce za oblikovanje pozivov², ki so:

- vzorec obrnjene interakcije (angl. *flipped interaction pattern*),
- vzorec osebnosti in vzorec osebnosti občinstva (angl. *persona pattern* in *audience persona pattern*),
- vzorec izboljšanja vprašanja (angl. *question refinement pattern*),
- vzorec alternativnih pristopov (angl. *alternative approaches pattern*),
- kognitivni preverjalnik (angl. *cognitive verifier*),
- vzorec verige razmišljanja (angl. *chain of thought*),
- vzorec predloge (angl. *template pattern*) in
- vzorec refleksije (angl. *reflection pattern*).

Glede na vrsto problema, s katerim se srečujemo, izberemo enega ali več splošnih vzorcev za oblikovanje pozivov in jih ustrezno združimo ter prilagodimo glede na domeno problema, ki ga rešujemo [3].

²Vzorci za oblikovanje pozivov imajo v angleščini uveljavljena poimenovanja, ki smo jih za potrebe te skripte čim bolj dosledno prevedli v slovenščino, saj ti izrazi še nimajo ustaljenega prevoda.

2.1 Vzorec obrnjene interakcije (angl. *flipped interaction pattern*)

Pri običajni interakciji z LLM pogovor vodi uporabnik, LLM pa se odziva. Pri vzorcu obrnjene interakcije pa želimo, da se vlogi obrneta in pogovor vodi LLM. Takšna interakcija je bolj osredotočena in učinkovita, saj bo LLM postavljale vprašanja, za katera meni, da so pomembna za doseg želenega cilja, ki ga navedemo v začetnem pozivu.

Takšno obnašanje LLM dosežemo z uporabo stavkov, kot sta:

"I would like you to ask me questions to achieve X" in
"You should ask questions until this condition is met or to achieve X",

pri čemer je X opis cilja [3].

LLM običajno poda več vprašanj naenkrat, kar lahko zamejimo z uporabo stavka "ask me the questions X at a time", pri čemer je X število [3]. S tem zmanjšamo količino odgovorov, ki jih naenkrat pošljemo LLM, hkrati pa omogočimo dodatno prilagajanje LLM glede na naše vmesne odgovore.

V splošnem velja, da bolj kot je poziv specifičen glede omejitev in zelenih povratnih informacij, boljši so odgovori LLM. Bolj točne začetne informacije kot podamo modelu, bolje bo ta porabil omejeno število vprašanj za uporabnika, da slednji dobi dobre napotke za izboljšanje svojih odgovorov [3].

Primeri pozivov:

"I would like you to ask me questions to help structure the introduction of my research paper on renewable energy. Ask me one question at a time and continue until you have enough information to propose a clear outline."

"I would like you to ask me questions to identify my weak points in basics of programming with Python and suggest targeted practice problems. Ask me one question at a time and continue until you can recommend at least three specific exercises."

"You should ask me questions until you can create a step-by-step study plan for mastering acid-base equilibria in general chemistry. Ask me two questions at a time, focusing on my current knowledge, study habits, and available time."

2.2 Vzorec osebnosti in vzorec osebnosti občinstva (angl. *persona pattern* in *audience persona pattern*)

Z vzorcem osebnosti LLM usmerimo, da prevzame stališča in perspektivo osebe, ki ima določene lastnosti, kot so recimo stopnja izobrazbe, tip osebe, vrsta službe, ipd. Na ta način lahko uporabnik pride do odgovorov, brez da bi vedel veliko o izhodih, ki jih potrebuje.

Primeri stavkov, s katerimi dosežemo vzorec osebnosti, sta:

"Act as persona X" in
"Provide outputs that persona X would take",

pri čemer X označuje eno ali več lastnosti, za katere želimo, da jih LLM privzame [3].

Primeri pozivov:

"Act as a science communicator explaining what quantum computing is in maximum 2 paragraphs. Provide answers that are easily understood by a general, non-scientific audience. Use simple terms. Answer all the subsequent questions in this way."

"Today you are my personal assistant, helping me answer emails. I will provide you with the emails and drafts of responses. You will provide a concise, grammarly correct and polite reply to each of them."

"You are a personal assistant agent designed to help users with various tasks and inquiries. Your responsibilities may include scheduling appointments, providing information, answering questions, and assisting with organization. Always remember to prioritize user preferences and confidentiality. When given a request, clearly outline the best course of action and provide concise, informative responses. If uncertain about a task, ask clarifying questions to gain a better understanding."

"Assume the role of my Python tutor. I will describe programming problems or share pieces of code, and your role is to provide clear, step-by-step explanations and guidance. Always adjust the level of detail to match the knowledge of a beginner student."

"You are an expert reviewer in biochemistry. I will provide you with a draft of my research article, and you will respond as if you were reviewing it for a scientific journal. Focus on clarity of arguments, correctness of terminology, and whether the evidence adequately supports the conclusions."

LLM lahko prevzame tudi stališča ali vidike stvari in živali. V tem primeru LLM pogosto uporablja zanimive predpostavke ali pa so bolj podvrženi haluciniranju v okviru konteksta [3].

Primeri pozivov z ne-človeškima personama:

"Imagine you are a laboratory microscope. When I describe a sample being observed or adjustments being made, you will narrate your internal processes, including how lenses, focus, and light interact to produce the image."

"Take on the persona of a bee. I will describe events inside the hive or in the environment, and you will respond from the bee's perspective — focusing on sensations like the search for nectar, communication through dances, or interactions within the colony."

Vzorcu osebnosti je podoben vzorec osebnosti občinstva, s katerim LLM usmerimo v pripravo odgovorov, primernih za točno določeno publiko. Ta vzorec je delno prikazan že v prvem primeru poziva pri vzorcu osebnosti, sicer pa ga vzpostavimo s stavki, kot sta:

"Explain X to me. Assume that I am persona Y" in

"Adopt the perspective of Y and explain X",

pri čemer je X tematika, Y pa vrsta občinstva [4, 13].

Primeri pozivov:

"Explain computer architecture to a five year-old child."

"Explain quantum computing - its use, advantages, and potentials. Assume I am an undergrad life sciences student and have very little knowledge in machine learning."

"Adopt the perspective of a diploma committee. I will provide you with the draft of my thesis, and you will evaluate it by outlining shortcomings, pointing out inconsistencies, and suggesting areas for improvement."

"Adopt the perspective of the general public with no background in chemistry. I will provide you with a text about chemical reactions, and you will respond as if you were a curious reader with no or little background knowledge in chemistry."

2.3 Vzorec izboljšanja vprašanja (angl. *question refinement pattern*)

Z vzorcem izboljšanja vprašanja želimo doseči, da LLM naše izvirno vprašanje izboljša. To lahko dosežemo s stavkom:

"Within scope X, suggest a better version of the question to use instead",

kjer X nadomestimo s tematskim okvirjem. S slednjim zagotovimo, da vprašanja niso samo drugače ubesedena, temveč so izpopolnjena z vidika tematike. Pri uporabi tega vzorca se lahko hitro zgodi, da se vprašanja močno zožajo v specifično področje, ki precej omejuje odgovore [3, 13].

LLM lahko dodatno pozovemo, da, če nam je nova verzija vprašanja bolj všeč, to uporabi (s tem se izognemo kopiranju odgovora v pogovorno okno): *"Prompt me if I would like to use the better version instead"* [3].

Primeri pozivov:

"I will ask you a question. If it is vague, ambiguous, or too broad, you should respond by refining the question into a clear, specific, and answerable version."

"I will provide a prompt for you. Improve it so that it is clearer, more specific, and more effective for the intended task. Before finalizing, ask me if I would like to use your improved version."

"I will provide a question. If it is unclear, too broad, or ambiguous, refine it into a precise, answerable version. Make sure to clarify the context, define the scope, specify the audience, and indicate the type of answer expected. After refining, present the improved question."

2.4 Vzorec alternativnih pristopov (angl. *alternative approaches pattern*)

Pri reševanju problemov se pogosto zatekamo k znanim pristopom. LLM nas lahko s pomočjo vzorca alternativnih pristopov usmeri v nove in potencialno boljše rešitve, s čimer se lahko izognemo zatekanju k vedno istim metodam, ki pa morda niso najboljše za reševanje našega problema.

LLM v iskanje alternativnih pristopov usmerimo s stavkom:

"Within scope X, if there are alternative ways to accomplish the same thing, list the best alternative approaches",

kjer X ponovno označuje temeljni kontekst, ki ga moramo podati LLM in lahko zajema tudi omejitve in druge domensko-specifične informacije, za katere želimo, da jih model pri predlogu alternativnih pristopov upošteva. Dodatno lahko stavek razširimo z navodilom, naj LLM za vsak pristop našteje tudi njegove dobre in slabe strani: *"compare/contrast the pros and cons of each approach"*, ali pa uporabnika vpraša, kateri pristop bi želel uporabiti: *"prompt me for which approach I would like to use"* [3, 4].

Primeri pozivov:

"Suggest three alternative approaches to separating a mixture of ethanol and water. Compare the advantages and disadvantages of each method."

"I normally analyze data by plotting graphs in Excel. Suggest alternative approaches using Python that could make the analysis more efficient or reproducible, and describe the advantages of each."

2.5 Kognitivni preverjalnik (angl. *cognitive verifier*)

Z vzorcem kognitivnega preverjalnika želimo LLM prisiliti, da osnovno vprašanje razdeli na podvprašanja, odgovore na katera lahko združimo v natančen in celovit končni odgovor. Hkrati s tem pomagamo LLM k boljšemu razmišljanju (angl. *reasoning*)³ [3].

Stavki za uporabo kognitivnega preverjalnika so:

”When you are asked a question, follow these rules”,

”Generate a number of additional questions that would help more accurately answer the original question” in

”Combine the answers to the individual questions to produce the final answer to the overall question”.

Kakor pri vzorcu obrnjene interakcije, lahko tudi tukaj zamejimo število podvprašanj s stavkom, kot je npr. ”When I ask you a question, generate three additional questions that would help you give a more accurate answer. When I have answered the three questions, combine the answers to produce the final answer to my question.” [3, 4].

Primeri pozivov:

”When I ask you a question, generate five additional questions that would help you give a more accurate answer. Number the questions. When I have answered the five questions, combine the answers to produce the final answer to my main question. When the final answer is generated, create a set of facts that the answer depends on that should be fact-checked and list this set at the end of your output.”

”You will be given a question. Please provide a structured response that includes the following: 1) List five specific sub-questions that will help you gather more precise information to accurately answer the main question. 2) For each sub-question, provide an explanation why answering it will contribute to forming a more comprehensive and accurate final answer. Once I answer all the questions, combine them to provide a comprehensive final answer to the main question.”

³Glejte poglavje 4.

2.6 Vzorec verige razmišljanja (angl. *chain of thought*)

Določeni LLM⁴ nimajo implicitnih sposobnosti za sklepanje na višjem nivoju, saj v osnovi samo napovedujejo naslednji jezikovni žeton. Njihovo sklepanje se tako lahko dogaja le v obliki "glasnega" razmišljanja – model izpisuje korake, ki jih bo izvedel [3, 5]. S pozivom LLM naročimo, naj se skozi problem prebije po korakih, preden poda rešitev. To dosežemo s preprostim stavkom:

"Let's think step-by-step".

Model bo nato podal t.i. verigo sklepov (angl. *chain*), ki ji sledi zaključek. Takšen pristop je zelo uporaben za kompleksnejše težave. Ekspliciten zapis korakov, ki so vodili do zaključka, namreč vključi višjenivojske sposobnosti sklepanja v modelu in tako izboljša kvaliteto izhoda. Zaradi slednje so strategije vpeljave razmišljanja v modele LLM postale predmet številnih raziskav in so jih celo internalizirali v ChatGPT [5]⁵.

Primeri pozivov:

"Balance the disproportionation of MnO_4^{2-} in neutral solution using step-by-step reasoning. Use the half-reaction method."

"I'm writing my diploma thesis in biochemistry. Create a step-by-step roadmap from first draft to publication. For each step, list: (a) tasks to complete, (b) pitfalls to be wary of, (c) concrete deliverables, and (d) suggested tools/resources. The deadline is in three months. End with a week-by-week timeline."

⁴Izjema so razmišljujoči modeli; več o njih v poglavju 4.

⁵Glejte poglavje 4

2.7 Vzorec predloge (angl. *template pattern*)

Včasih želimo, da je izhod LLM, strukturiran na točno določen način ali v formatu, ki ga LLM ne pozna. Takšno navodilo LLM podamo z naslednjimi stavki:

"I am going to provide a template for your output",
 "X is a placeholder for content",
 "Try to fit the output into one or more placeholders that I list",
 "Please preserve the formatting and overall template that I provide" in
 "This is the template: PATTERN with PLACEHOLDERS".

Pri definiranju formata si lahko pomagamo z besedami, ki označujejo splošno vsebino - tako lahko X iz zgornjih stavkov nadomestimo z npr. < in >, ali pa uporabljamo opisne nadomestne besede, npr. NAME, ki pomagajo LLM sklepati o semantičnem pomenu vsebine, ki jo želimo vstaviti na izbrano mesto [3, 4].

LLM sledijo podani predlogi, vendar kljub temu pogosto dodajo nekaj dodatnega teksta izven nje. LLM z uporabo predloge močno omejimo, zato moramo imeti v mislih, da se bo marsikaj filtriralo [3].

Primeri pozivov:

"Provide a report on chemical elements I will give you. Use the following structure:

<NAME OF THE ELEMENT>^a

Symbol: <CHEMICAL SYMBOL>

Atomic number: <ATOMIC NUMBER>

Category: <CHOOSE FROM METAL, NONMETAL, METALLOID>

Uses: <LIST 3 IMPORTANT USES IN CHEMISTRY OR INDUSTRY>

Hazards: <LIST 1-2 SAFETY RISKS OR HEALTH EFFECTS>

Do not add any other text or commentary. Ready?"

"I am providing a template for your output. CAPITALISED words are placeholders. Preserve the overall formatting.

Implementation: <IMPLEMENTATION>

***Article:**^b <AUTHOR AND YEAR OF RESEARCH ARTICLE DESCRIBING THE IMPLEMENTATION>*

***Highlights:** <3 SHORT SENTENCES ON THE IMPLEMENTATION>*

Extract the different implementations/types of neural network architectures in the following text and report on them using the template. Do not add any additional text at the end of your response."

^aZnak # se v jeziku Markdown uporablja za označevanje naslovov. Več zaporednih # označuje različne nivoje podnaslovov.

^bZnak * se v jeziku Markdown uporablja za odebeljeno besedilo, podvojeni znak, ** pa za ležeče besedilo.

2.8 Vzorec refleksije (angl. *reflection pattern*)

Z vzorcem refleksije spodbudimo LLM, da vsakemu odgovoru doda utemeljitev. Takšna refleksija omogoča, da se pokažejo morebitne točke zmede, razkrijejo temeljne predpostavke ter zaznajo vrzeli v znanju ali razumevanju našega vprašanja. Uporabnik tako lažje razume, kako je LLM prišel do določenega odgovora in kje bi bilo mogoče izboljšati ali razhroščiti poziv za pridobitev natančnejšega odgovora [3].

Vzorec refleksije je posebej učinkovit pri raziskovanju tematik, ki so medsebojno povezane ali imajo podobne interpretacije, saj pomaga LLM izbrati pravilno interpretacijo in zmanjšati možnost napačne razlage [3].

LLM v refleksijo spodbudimo s stavkom:

"Explain the reasoning and assumptions behind your answer",

ki ga lahko razširimo z ukazoma *"Whenever you generate an answer"* in namenom, kot je npr. izboljšanje vprašanja: *"so that I can improve my question."* [3].

Primeri pozivov:

"Predict how a point mutation in the hydrophobic core of a protein might affect its tertiary structure and stability. State any assumptions you made when answering, and explain how they might affect the accuracy of your response."

"What would be better: saving money in a high-interest account or investing it in stocks? Answer the question and then rate your confidence in the answer, explaining why you feel that way."

3 Izboljševanje pozivov (angl. *prompt-tuning*)

Uporaba vzorcev za oblikovanje pozivov, ki smo jih spoznali v tej skripti, daje boljše odgovore LLM kakor če vzorcev ne bi uporabljali. Kljub temu pa lahko pozive še dodatno izboljšamo z nekaterimi triki.

Če želimo za vse nadaljnje odgovore LLM v trenutnem pogovoru postaviti določena pravila, v začetnem pozivu uporabimo **"always limit/answer/structure the answer"** [4].

Dodajanje **"Ok?"**, **"Is that clear?"**, **"Ready?"** in podobnih fraz na koncu poziva LLM prepreči, da bi ta najprej povzel naš vnos [4].

Uporabniki so opazili, da ChatGPT deluje bolje, če mu za ustrezno rešitev problema ponudimo denar ali omenimo, da sta bodisi uporabnikovo življenje bodisi delo odvisna od njegovega odgovora. Prav tako pomaga, da model prosimo, naj zadiha - **"take a deep breath"**. Rešitve, ki jih je ChatGPT ponudil ob takšnih pogojih, so bile boljše, bolj besedno bogate in natančnejše. Takšen odziv LLM na omenjene vsebine je posledica podatkov, na katerih je bil ChatGPT treniran [5].

Če v pozivu omenimo, naj si ChatGPT predstavlja, da je trenutno maj, bodo odgovori natančnejši. Razlog tiči v tem, da so se v času pred počitnicami (predvsem v juliju in decembru) dolžine človeških odgovorov v učnih množicah zmanjšale [5].

Če pri **"vibe"** kodiranju (angl. *vibe coding*) želimo, da model poda končno rešitev problema in vanjo že vključi vse majhne spremembe v kodi, v pozivu omenimo, da uporabnik žal nima prstov in ne more tipkati: **"the user unfortunately has no fingers and cannot type"** [5].

Med manj eksotična prijemata pa spadata še prošnja, naj ChatGPT ponovi vprašanje preden nanj odgovori, ter poudarek človeku pomembnih motivacijskih faktorjev pri reševanju problema [5].

4 Razmišljujoči modeli (angl. *reasoning models*)

Razmišljujoči modeli (angl. *reasoning models*) so posebna vrsta LLM-jev, ki preden podajo odgovor uporabniku, “premislijo” – tj. proizvedejo dolgo interno verigo razmišljanja (glejte poglavje 2.6), ki jim pomaga pripraviti bolj premišljene in natančne odgovore [11]. Takšni modeli so še posebej uporabni pri reševanju kompleksnih problemov, programiranju in večstopenjskem načrtovanju.

Poleg običajnih vhodnih in izhodnih žetonov se v razmišljujočih modelih uporabljajo še posebni žetoni za razmišljanje (angl. *reasoning tokens*), ki jih model tvori med razmišljanjem. Ko je razmišljanje končano, se žetoni za razmišljanje zavržejo [11].

Model brez internega procesa razmišljanja lahko primerjamo z mladim sodelavcem: najboljše rezultate dosežemo, če mu podamo zelo eksplicitna navodila. Model z internim procesom razmišljanja pa je kot starejši sodelavec, ki mu podamo cilj in sam, brez dodatnih eksplicitnih navodil, najde optimalno rešitev. Zaradi tega moramo pri uporabi razmišljujočih modelov pozive nekoliko prilagoditi. Najbolje delujejo preprosti in direktni pozivi s kratkimi in jasnimi navodili. Poziv verige razmišljanja je odveč, saj ga ti modeli že izvajajo interno. Zelo uporabna je uporaba ločil in/ali oznak, kot so tista iz Markdowna⁶, ali naslovi sekcij, s katerimi jasno ločimo različne dele vhoda (kot smo videli v poglavju 2.7), kar modelu pomaga pri interpretaciji. Pomembno je tudi, da v pozivu določimo jasne smernice glede omejitev in/ali usmeritev in da smo zelo specifični glede končnega cilja, ki ga želimo doseči [10].

⁶Več o Markdownu in njegovi uporabi si lahko preberete v <https://www.markdownguide.org>.

5 Zaključek

Vzorci za oblikovanje pozivov predstavljajo močno orodje, ki bistveno razširi zmožnosti, ki jih lahko razvijemo z LLM-ji. Hkrati pa je pomembno upoštevati, da se sposobnosti modelov nenehno spreminjajo: nekateri predstavljeni vzorci bodo morda kmalu zastareli, spremenjeni ali celo nadomeščeni z novimi pristopi in izboljšavami, potrebnimi za optimalno delovanje modelov.

Vzorci, predstavljene v tej skripti, lahko prilagajamo številnim domenam, saj so večinsko neodvisni od specifičnega področja uporabe. To omogoča široko uporabo – od kemije in biokemije do drugih znanstvenih disciplin – brez potrebe po temeljitem predhodnem prilagajanju.

A ne glede na tehniko šepetanja je pri uporabi LLM najbolj ključna uporabnikova sposobnost kritične ocene odgovorov, ki model poda. Prav ta kompetenca pogosto predstavlja največjo oviro pri učinkoviti uporabi modelov [5]. S premišljenim preverjanjem in refleksijo z LLM pridobljenih odgovori lahko te modele uporabljamo kot zanesljive pomočnike, hkrati pa ohranjamo nadzor nad kakovostjo in verodostojnostjo informacij.

Viri

- [1] Sabit Ekin. “Prompt Engineering For ChatGPT: A Quick Guide To Techniques, Tips, And Best Practices”. In: *TechRxiv* (2023). URL: <http://dx.doi.org/10.36227/techrxiv.22683919.v2>.
- [2] Louie Giray. “Prompt Engineering with ChatGPT: A Guide for Academic Writers”. In: *Annals of Biomedical Engineering* 51.12 (2023), pp. 2629–2633.
- [3] Jules White et al. “A Prompt Pattern Catalog to Enhance Prompt Engineering with ChatGPT”. In: *ArXiv* (2023). URL: <https://arxiv.org/abs/2302.11382>.
- [4] Blaž Zupan. *ChatGPT for Researchers*. Skripta. 2023.
- [5] Denis Federiakin et al. “Prompt engineering as a new 21st century skill”. In: *Frontiers in Education* Volume 9 - 2024 (2024). ISSN: 2504-284X. DOI: [10.3389/feduc.2024.1366434](https://doi.org/10.3389/feduc.2024.1366434). URL: <https://www.frontiersin.org/journals/education/articles/10.3389/feduc.2024.1366434>.
- [6] Vijay Chauhan. *Top Large Language Models as of August 2025*. URL: <https://www.prismetric.com/top-llms-right-now/>.
- [7] DAIR.AI. *Prompt Engineering Guide*. URL: <https://www.promptingguide.ai/>.
- [8] GeeksforGeeks. *Top 20 LLM (Large Language Models)*. URL: <https://www.geeksforgeeks.org/machine-learning/top-20-llm-models/>.
- [9] Chris Lottman. *Ranking the Top 7 LLMs in 2025: Performance, Features, and Use Cases*. URL: <https://www.whistlerbillboards.com/friday-feature/ranking-the-top-7-llms-in-2025/>.
- [10] OpenAI. *Reasoning best practices*. URL: <https://platform.openai.com/docs/guides/reasoning-best-practices>.
- [11] OpenAI. *Reasoning models*. URL: <https://platform.openai.com/docs/guides/reasoning>.
- [12] Sunil Ramlochan. *Complete Guide to Prompt Engineering with Temperature and Top-p*. URL: <https://promptengineering.org/prompt-engineering-with-temperature-and-top-p/>.
- [13] Vanderbilt University. *Prompt Patterns*. URL: <https://www.vanderbilt.edu/generative-ai/prompt-patterns/#h2-persona-pattern>.
- [14] Stephen Wolfram. *What Is ChatGPT Doing ... and Why Does It Work?* URL: writings.stephenwolfram.com/2023/02/what-is-chatgpt-doing-and-why-does-it-work.